


RAG 多輪對話設計指南

在 Retrieval-Augmented Generation (RAG) 應用中加入**多輪澄清機制**，可有效避免一次性詢問帶來的資訊落差，並逐步引導使用者說出真正需求。以下從架構、對話策略、技術要點到 UX 實務給出完整設計藍圖。

多輪 RAG 對話流程總覽



多輪 RAG 對話設計流程示意圖

1. 架構總覽

1.1 角色分層

- 1. Front-end Chat Interface
 - 即時呈現候選澄清選項、答案與來源
- 2. Dialogue Manager
 - 控制 turn-taking、意圖偵測、回合計數
- 3. History-Aware Retriever
 - 利用最新提問 + 歷史對話生成「獨立檢索查詢」
- 4. Vector Store / Index
 - 向量檢索 + Metadata filter
- 5. LLM Answer Generator
 - 將檢索片段（context）與使用者問題合併生成回覆
- 6. Feedback & Logging
 - 儲存澄清問答供 RLHF 或 RLAIF 強化

1.2 關鍵模組

模組	功能	核心技術	注意事項
Question Re-phraser	將含代詞/省略的追問重寫成獨立問題	history-aware prompt	避免過長上下文造成 token 爆
Ambiguity Detector	判定是否需要澄清	信心閾值、歧義類型分類	引入二階標註「未來回合績效」可提升判定準確 ^[1]
Clarification Generator	產生針對性澄清問句	AT-CoT / ReAct	問句須可由使用者單句回答
Disambiguation UX	提供多選或自由輸入	button list、quick reply	視通路（App/Web/LINE）調整

2. 多輪對話策略

2.1 澄清時機

- 1. **Retriever 回傳不足**：top-k 得分低於閾值
- 2. **多意圖競合**：>1 個意圖分數相近（如 0.55 vs 0.53）
- 3. **問題含空格槽（slot）**：日期、人名、產品型號缺失

2.2 澄清類型

類型	範例	設計提要
缺值填充	「請問想查哪一天的報價？」	slot-filling；限制回答格式
多意圖選擇	「您要退貨還是查詢退貨進度？」	提供 2-3 選項；加入「其他」
範圍限定	「是指公司整體營收，還是特定事業部？」	引導到最小可回答單元
資料時效	「需要今年最新財報，還是歷史平均？」	決定檢索時間窗口

2.3 對話結束判定

1. 使用者明確肯定（“沒問題了”）
2. 連續兩次回答「不需要更多資訊」
3. 回合數達上限（如 8 turns）自動收斂總結

3. 技術實踐細節

3.1 History-Aware Retriever

```
contextualize_prompt = """
Given chat history and latest user question,
produce a standalone search query without answering.
"""

retriever_chain = create_history_aware_retriever(
    llm, vector_retriever, contextualize_prompt
)
```

- 減少多餘歷史訊息干擾
- 支援 streaming API，保持低延遲

3.2 Clarification Question Selection

1. 產生 N=3 候選問句
2. 估算每句「信息增益」≈ 檢索置信度提升
3. 選擇最高者發出；其餘存入記憶庫供日後微調

3.3 Query Decomposition

對複合問題先分解子詢問，再逐一檢索並合併推理，可提升多 hop 指標 36%^[2]。

3.4 RLHF / Double-Turn Preference

將「澄清後回答正確」視為 reward，優於單回合標註^[1]。

4. UX 設計原則

4.1 一致、自然的語氣

- 系統提示（system prompt）確保語調前後一致
- 回覆過長時提供 TL;DR + 「想看詳細？」連結

4.2 明確顯示可選動作




Example of a multi-turn WhatsApp chatbot conversation guiding a user through a product return process with options and follow-up questions.

4.3 當前上下文提示條

- 在輸入框上方簡短顯示目前查詢主題
- 提供「修改」按鈕快速回溯

4.4 檔案多源支援

- 後台允許一次上傳 PDF/Excel/Word，建立向量索引
- 以 Metadata 標示版本、語言、保密等級



Chatbot platform interface showing multi-source file uploads to support instant answers in multi-turn conversations.

5. 性能與評估

指標	目標值	量測方式
Clarification Trigger Precision	≥ 0.85	人工標註隨機樣本
Turn-per-Query 平均	≤ 3	日誌統計
Top-1 Answer F1	+10% vs 無澄清	HotpotQA / 自訂測試集
UX CSAT	$> 4.3/5$	事後問卷

6. 迭代與最佳化

1. 追蹤每回合澄清問句 → 回答正確率，調整 prompt
2. 對高頻「無答案」案例進行資料補充或內部工具 hook
3. 週期性重新向量化最新文件，避免時效落差

結語

透過**歧義檢測** → **精準澄清** → **動態檢索** → **答覆生成**的閉環設計，RAG 應用能在保持高準確度的同時，讓使用者以最少步驟獲得真正想問的答案，並持續透過回饋強化整體體驗。



1. <https://arxiv.org/html/2410.13788v1>
2. <https://arxiv.org/abs/2507.00355>